信息检索实验报告

——倒排索引

实验名称。	倒排索引
班级	软件学院 14 级二班
学号-姓名	刘嘉洋-1412620
实验日期	2016年9月23日
至	2016年10月13日
评分教师_	实验报告成绩
评分日	在 日 日

一、实验目的:

- 了解信息检索原理的基本思路
- 掌握倒排索引的基础构建过程

二、实验环境

Ubuntu v16.04 Qt Creator 4.0.2

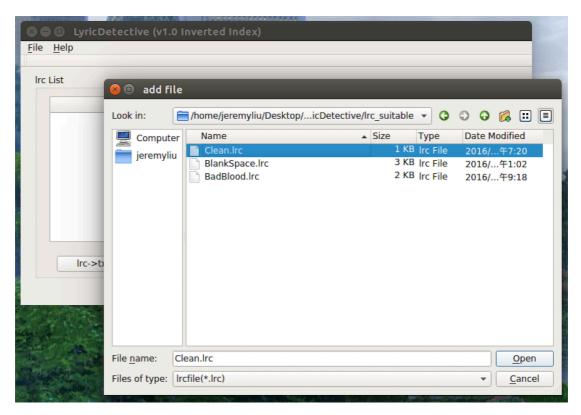
三、实验要求

- 编写程序实现为给定目录下 lrc(歌词)文件建立倒排索引文件
- 要求过滤掉 lrc 文件中的标识和时间标签

四、软件操作展示



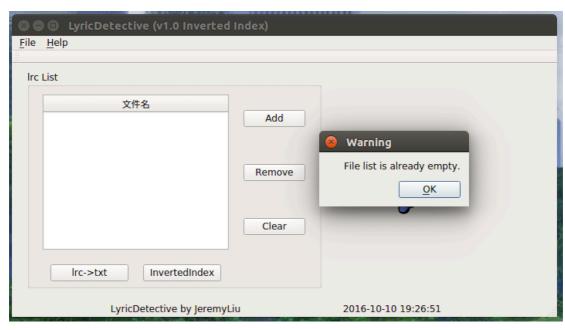
[图 1] LyricDetective"歌词探长"界面



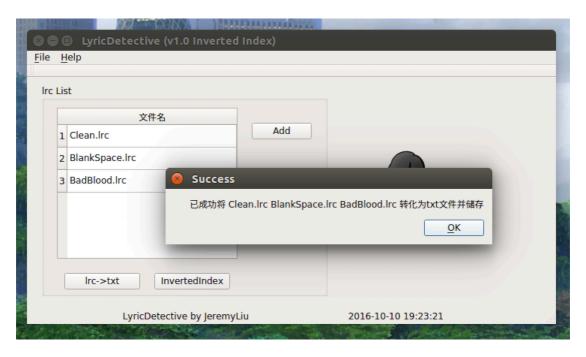
[图 2] 点击"ADD"按钮或通过 File 菜单中的"Add .lrc"显示添加歌词文件界面



[图 3] 完成.lrc 文件列表创建,其间可进行添加、移除、清空操作



[图 4] 移除或清空后若再进行删除操作,会弹出提示信息



[图 5] 点击"lrc->txt"按钮,将当前歌词列表进行标识与时间标签分离

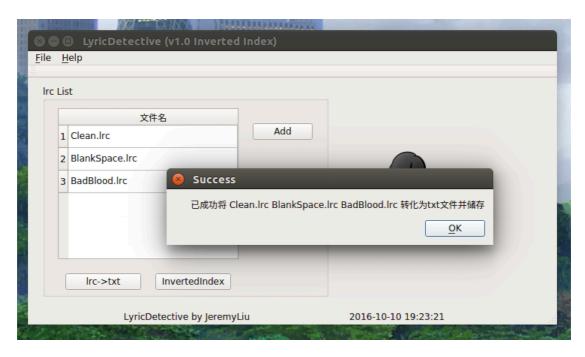
```
Deen * Pl

Save

Open *
```

[图 6.a] 原.lrc 文件格式样例

[图 6.b] 分析过滤后生成对应.txt 样例



[图 7] 点击"InvertedIndex"按钮,得到生成的倒排索引结果输出到 result.txt 中

```
🕽 🖨 📵 result.txt (~/Desktop/LyricDetective/txt_generated) - gedit
Open ▼
                                                                                                                                 Save
                                                                    [Clean.lrc, 2]
 1 "
                                     [BlankSpace.lrc, 2]
 2 "Oh
                                                                    [Clean.lrc, 28]
                                     [BlankSpace.lrc, 3]
 3 'Cause
                                     [BlankSpace.lrc, 3]
                                                                    [Clean.lrc, 6]
                                     [Clean.lrc, 1]
 5 -sheery
                                     [BlankSpace.lrc, 1]
                                                                   [Clean.lrc, 1]
                                     [Clean.lrc, 11]
[BlankSpace.lrc, 2] [Clean.lrc, 6]
[BadBlood.lrc, 2] [BlankSpace.lrc, 1]
[BadBlood.lrc, 11] [BlankSpace.lrc, 10]
[BadBlood.lrc, 8] [BlankSpace.lrc, 1]
 6 10
 7 Ain't
                                                                                               [Clean.lrc, 4]
 8 All
 9 And
                                                                                                  [Clean.lrc,
                                                                                                                   10]
                                                                                               [Clean.lrc, 9]
10 Band-aids
                                     [BlankSpace.lrc, 11]
                                                                     [Clean.lrc, 9]
11 Be
12 Blank
                                     [BlankSpace.lrc, 1]
                                                                    [Clean.lrc, 14]
                                                                  [Clean.lrc, 10]
[Clean.lrc, 6]
[BlankSpace.lrc, 6]
[Clean.lrc, 10]
13 Boy
                                     [BlankSpace.lrc, 4]
                                     [BlankSpace.lrc, 6]
[BadBlood.lrc, 10]
14 But
15 Cause
16 Cherry
                                     [BlankSpace.lrc, 2]
17 Clean
                                     [Clean.lrc, 1]
18 Did
                                     [BadBlood.lrc, 6]
                                                                 [BlankSpace.lrc, 1] [Clean.lrc, 9]
                                     [BlankSpace.lrc, 10]
[BlankSpace.lrc, 3]
19 Don't
                                                                    [Clean.lrc, 4]
[Clean.lrc, 10]
20 Find
                                     [BlankSpace.lrc, 2]
[BlankSpace.lrc, 8]
                                                                    [Clean.lrc, 6]
21 God
                                                                    [Clean.lrc, 9]
22 Got
                                                                    [Clean.lrc,
23 Grab
                                     [BlankSpace.lrc,
                                                            1]
                                                                                    10]
                                     [BadBlood.lrc, 8]
[BadBlood.lrc, 10]
                                                              [BlankSpace.ĺrc, 1]
24 Hey!
                                                                                               [Clean.lrc, 9]
                                    [BadBlood.lrc, 10] [BlankSpace.lrc, 18]
[BlankSpace.lrc, 8] [Clean.lrc, 10]
[BadBlood.lrc, 1] [BlankSpace.lrc, 9] [BadBlood.lrc, 1] [BlankSpace.lrc, 3] [BlankSpace.lrc, 3]
25 I
                                                                                                 [Clean.lrc, 28]
26 I'll
27 I'm
                                                                                                [Clean.lrc, 6]
28 If
                                                                                              [Clean.lrc, 3]
                                     [Clean.lrc, 2]
[Clean.lrc, 19]
29 It
30 Just
                                     [BlankSpace.lrc, 9] [Clean.lrc, 9] [Clean.lrc, 6] [BlankSpace.lrc, 2] [Clean.lrc, 6]
31 Keep
32 Let
33 Love's
34 Magic
                                     [BlankSpace.lrc, 2]
                                                                    [Clean.lrc, 9]
35 Nice
                                     [BlankSpace.lrc, 1]
                                                                    [Clean.lrc, 1]
36 No
                                     [BlankSpace.lrc, 1]
                                                                    [Clean.lrc,
                                                                [Clean.lrc, 6]
[BlankSpace.lrc
                                     [BadBlood.lrc, 6]
[BadBlood.lrc 3]
37 Now
                                     [BadBlood.lcc
                                                                                               [Clean.lcc
38.0h
Saving file '/home/jeremyliu/Desktop/LyricDetective/txt_... Plain Text ▼ Tab Width: 8 ▼ Ln 342, Col 84 ▼ INS
```

[图 8] 倒排索引生成结果 result.txt

五、核心代码说明

该软件需要解决的核心问题有:

- QTableWidget 中. 1rc 列表的增、删和清空
- .1rc 文件中标识和时间标签的过滤
- 倒排索引的生成
- 生成结果的存储数据结构

5.1 QTableWidget 中. Irc 列表的增、删和清空

首先在 initial()中定义 QTableWidget 的属性:

```
35ui->twgFileList->setColumnCount(1);36ui->twgFileList->setRowCount(0);37QStringList headers;38headers << "文件名";</td>39ui->twgFileList->setHorizontalHeaderLabels(headers);40ui->twgFileList->horizontalHeader()->setStretchLastSection(true);41ui->twgFileList->setSelectionBehavior(QAbstractItemView::SelectRows); // 设置选择行为时每次选择一行
```

在主窗体头文件中定义歌词文件名列表存储形式:

QVector<QString> listFileName

在 ADD 按钮对应的信号槽出发函数中进行文件打开与选择操作,并将文件名 append 进容器中:

由此, Remove 和 Clear 按钮操作实现即转换为对该 QVector 容器的操作。 需要注意的是,每次操作的最后都需要进行在 TableWidget 中的重新显示。

5.2. Irc 文件中标识和时间标签的过滤

这项功能的关键点在于对字符串的识别,而恰恰在此我被僵持住了很久,原因在于,QT中的字符串类型 QString 并没有标准 C++ 11 中 string 的诸如find_first_of(),最终我选择在QT环境中引入std库进行形式为"std::String",虽然产生了QString与std::string之间多次的相互转换,但使得问题得以解决。过滤逻辑如下:

```
getLyricHeader(str);
std::string timeTemp[MAX_LYRCE_REPEAT_NUM]; // 保存信息
m = str_string.find_first_of('[');
n = str_string.find_first_of(']');
while (m >= 0 && m <= str_string.length() && n >= 0 && n <= str_string.length() && str != "")
    timeTemp[p] = str_string.substr(m + 1, n - 1);
   m = str_string.find_first_of('[');
   n = str_string.find_first_of(']');
QString contentTemp = QString::fromStdString(str_string); // important
    if (lineNum == 1)
    lyric[lineNum].startTime = QString::fromStdString(timeTemp[i]);
    if (timeTemp[i + 1] != "") // 连续的
        lyric[lineNum].endTime = QString::fromStdString(timeTemp[i + 1]);
    if (lineNum - 1 >= 0 && i == 0) // 设置上一个的endTime
       lyric[lineNum - 1].endTime = lyric[lineNum].startTime;
    lyric[lineNum].lineNum = lineNum;
    lyric[lineNum].lyricContent = contentTemp;
    lineNum++;
```

最后将过滤结果分别保存至与. 1rc 文件名一致的. txt 文件中:

```
| OString txt_FileName = "/home/jeremyliu/Desktop/LyricDetective/txt_generated/" + file_CurrentProccessed_lrc + ".txt";
| OFile file(txt_FileName);
| OFILE file(txt_File
```

5.3 倒排索引的生成以及生成结果的存储结构

在此处的方法进行了借鉴, 出处为:

 $\underline{\texttt{http://blog.csdn.net/okiwilldoit/article/details/51362839}}$

但我在其基础上进行了优化,主要着力点为:

- 调整为归一化的 Map 存储结构,方便了最后将结果通过 Iterator 遍历输出的时间复杂度。
- 重新调整了各个分步功能的实现位置,减少了全局变量的数量,使代码逻辑 进一步清晰化。

```
if(strlen(word) == 0)
{
    return;
}

std::string word_str = word;

std::string file_name_str = file_CurrentProccessed_incerted.toStdString();

// qDebug() << QString::fromStdString(word) << ":" << QString::fromStdString(file_name_str);

std::map<std::string, std::map<std::string, int>>::iterator it;

it = result_index_.find(word_str);

if(it == result_index_.end()) // not found
{
    file_word_count.insert(std::pair<std::string, int>(file_name_str,1));
    result_index_[word_str] = file_word_count;
}

else

file_word_count = result_index_[word_str];
file_word_count[file_name_str] ++;
    result_index_[word_str] = file_word_count;
// qDebug() << result_index_[word_str];
}

}</pre>
```

最终,将得到的嵌套 Map 结构的倒排索引结构通过遍历器输出至 result. txt 文件中:

至此,该软件实现倒排索引的 1.0 版本全部完成,后期将会在界面 1rc_1ist 的 Group 右侧添加布尔查询的用户操作端,从而实现从. 1rc 的解析、倒排索引的生成以及最后布尔查询的具体应用。

六、写在最后

感谢温延龙老师课上清晰的讲解,是对我倒排索引细节的掌握以及顺利制作完成 该软件的基础。